LA SELVA DE LOS DATOS

SESIÓN 2

AÑO 4026. EL DOCTOR TERA, EXPLORADOR DEL FUTURO Y FRIKI CONFESO DEL 2026, ATERRIZA EN LA SELVA DE LOS DATOS...

¡¡ES EL 2026!! ¡MI AÑO FAVORITO DE TODA LA HISTORIA!

4026

2026

BIENVENIDOS AL 2026

...Y DESCUBRE UN ASENTAMIENTO INTACTO DE AQUELLA ÉPOCA.

TPC-DS EN PARQUET SOBRE HDFS

UN DATA LAKE GUARDA LOS FICHEROS TAL COMO LLEGAN Y LOS ORDENA EN TRES TERRAZAS.

DE LA COPIA FIEL AL DATO LISTO PARA USAR...

GOLD: LISTO PARA USAR

SILVER: LIMPIO

2026

RAW: COPIA FIEL

¡PANTANO!

SIN ORDEN

DATA LAKES Y ARQUITECTURA MEDALLION

¡CUAC! SOY DUCK, UNA BASE DE DATOS. ¡Y VIAJO EN TU MOCHILA!

¿UNA BASE DE DATOS... SIN SERVIDOR?

SERVIDOR

DUCKDB NO ES UN SERVIDOR: ES UNA BIBLIOTECA QUE VIVE DENTRO DEL PROGRAMA.

QUÉ ES DUCKDB

TPC-DS ES UNA EMPRESA INVENTADA, CON TIENDAS FÍSICAS Y UNA WEB.

EL GENERADOR CREA UNOS 3 GB (SF3), IDÉNTICOS PARA TODO EL ALUMNADO.

¡UNA EMPRESA ENTERA, Y SIN ESPIAR A NINGUNA REAL!

TPC-DS

SF 3

2026

TIENDAS | CLIENTES | VENTAS

TPC-DS Y LA ESCALA SF3

¡8.132 MUNICIPIOS, CON SU POBLACIÓN Y SU SUPERFICIE!

2026

NGMEP
CC-BY 4.0
IGN.ES

LAS CIUDADES INVENTADAS DEL GENERADOR SE SUSTITUYEN POR MUNICIPIOS REALES DEL IGN.

INCORPORAR LOS MUNICIPIOS DEL IGN

COD_INE;NOMBRE;POBLACION;SUPERFICIE
01001000000;ARABA/�LAVA;1994,5872
1 2 3 4

CEROS INICIALES
01001 ES UN CÓDIGO, NO UN NÚMERO: SE LEE COMO TEXTO.

SEPARADOR
ES ';': LA COMA YA SE USA EN LOS DECIMALES.

LATIN-1
LEÍDA COMO UTF-8, LA Á SE ROMPE: HAY QUE DECIR LA CODIFICACIÓN.

COMA DECIMAL
1994,5872 NO ES UN NÚMERO HASTA DECIR QUE LA COMA ES EL DECIMAL.

EL MAPA VIENE ESCRITO A LA ANTIGUA: HAY QUE DECIRLE A DUCKDB CÓMO LEERLO.

LEER Y NORMALIZAR EL CSV

A CADA CIUDAD INVENTADA LE TOCA SIEMPRE EL MISMO MUNICIPIO: SE CALCULA, NO SE SORTEA.

UNA CIUDAD INVENTADA
FAIRVIEW TN

HUELLA MD5

UN MUNICIPIO REAL
MUNICIPIO Nº 4.512

NADA DE AZAR

2026

MISMA CIUDAD, MISMA HUELLA, MISMO MUNICIPIO. ¡SIEMPRE!

UNIR LAS DOS FUENTES

2450815 → ENE 1 1998

45296 → 12:34 56 S

EN LAS VENTAS, LA FECHA ERA UNA CLAVE: LOS DÍAS DESDE 1900 Y LOS SEGUNDOS DESDE LA MEDIANOCHE.

¿QUÉ DÍA ES EL 2450815?

EL 1 DE ENERO DE 1998. LO GUARDAMOS COMO FECHA DE VERDAD.

CONVERTIR LAS CLAVES DE FECHA Y HORA

PARQUET GUARDA CADA COLUMNA JUNTA Y LA COMPRIME. LEER UNA NO OBLIGA A LEER LAS DEMÁS.

NOMBRE	TIPO	PRECIO	MARCA

UNA TABLA, POR FILAS

PARQUET: NOMBRE | TIPO | PRECIO | MARCA

UNA COLUMNA, UN PAQUETE

2026

¡SI SÓLO QUIERO EL PRECIO, NO HACE FALTA ABRIR LAS DEMÁS!

ZSTD
COMPRIME

MATERIALIZAR LAS 18 TABLAS

HDFS REPARTE LOS FICHEROS EN BLOQUES ENTRE LAS ALDEAS (DATANODES). EL JEFE (NAMENODE) SÓLO LLEVA EL REGISTRO.

/DATALAKE/RAW/TPCDS

ALDEA 1 · ALDEA 2 · ALDEA 3

¿DÓNDE ESTÁ EL BLOQUE QUE BUSCO?

2026

EN LA ALDEA 2. YO SÓLO APUNTO DÓNDE ESTÁ.

DÓNDE ESTÁN FÍSICAMENTE LOS DATOS

LAS 18 TABLAS QUEDAN EN EL LAGO. LA BASE TEMPORAL SE TIRA: LO QUE CUENTA SON LOS PARQUET DE HDFS.

RAW: 18 TABLAS

~1 GB

BASE TEMPORAL

☑ TODAS CON SU _SUCCESS

¡TODO EN SU SITIO!

VALIDAR Y BORRAR LA BASE TEMPORAL

TRES GUÍAS, TRES CAMINOS PARA LEER EL MISMO PARQUET… Y UN ÚNICO RESULTADO.

ITEM.PARQUET

PYARROW
36.000
PRODUCTOS

POLARS
36.000
PRODUCTOS

DUCKDB
36.000
PRODUCTOS

¡LOS TRES DICEN LO MISMO!

LEER LA MISMA TABLA CON TRES BIBLIOTECAS

CADA VENTA ES UN RECIBO CON HILOS (CLAVES) QUE LLEVAN AL QUIÉN, AL QUÉ Y AL DÓNDE.

CLIENTE

PRODUCTO

VENTA WEB
CLIENTE
PRODUCTO
DOMICILIO
1 ENE 1998 · 12:34

DOMICILIO

LA FECHA NO NECESITA HILO: VA EN EL PROPIO RECIBO

UN HECHO Y SUS DIMENSIONES

¿QUIÉN? ¿QUÉ? ¿DÓNDE?

SIGO EL HILO Y ENCUENTRO LA FILA A LA QUE LLEVA.

UNA VENTA, CLAVE A CLAVE

¿QUIÉN HABRÁ COMPRADO MÁS COSAS?

ANTE UN DATASET DE VENTAS, LAS PRIMERAS PREGUNTAS SIEMPRE SON LAS MISMAS: CUÁNTO, QUÉ, CUÁNDO, DÓNDE Y A QUIÉN.

¿A QUÉ HORA SE COMPRA?

¿QUÉ SE VENDE MÁS CADA MES?

¿QUÉ PROVINCIA COMPRA MÁS?

2026

LAS PRIMERAS PREGUNTAS ANTE UN DATASET

¿QUIÉN HA COMPRADO MÁS POR LA WEB? SE AGRUPA POR CLIENTE Y SE CUENTAN SUS PEDIDOS.

1 PEDIDO
= 3 LÍNEAS

2

1

3

¡A CONTAR PEDIDOS, NO LÍNEAS!

¿GANARÁ EL QUE MÁS PEDIDOS HACE O EL QUE MÁS GASTA?

CLIENTE CON MÁS PEDIDOS

¿QUÉ PROVINCIA COMPRA MÁS? CUIDADO: SI NO SE DIVIDE POR HABITANTES, GANAN SIEMPRE LAS MÁS POBLADAS.

VENTAS

POR HABITANTE

÷ HABITANTES

BURBUJAS ILUSTRATIVAS

¿MADRID GANA… POR TENER MÁS GENTE?

VENTAS POR MIL HABITANTES: OTRA CLASIFICACIÓN.

VENTAS, POBLACIÓN Y DENSIDAD

¿CUÁNDO SE COMPRA? LA FECHA Y LA HORA DE CADA VENTA DAN EL CALENDARIO Y EL RELOJ DE LAS COMPRAS.

TIENDA: VENTAS POR MES

¿POR IGUAL EN TODO EL AÑO? NO.

X2

X3

E F M A M J J A S O N D

WEB: PEDIDOS POR HORA

0 3 6 9 12 15 18 21

AGOSTO-OCTUBRE: EL DOBLE. NOVIEMBRE-DICIEMBRE: EL TRIPLE.

CÓMO SE REPARTEN LAS VENTAS

EL MAPA DE LA EXPEDICIÓN

PARQUET

1 **GENERAR**
DUCKDB CREA LAS 24 TABLAS INVENTADAS DE TPC-DS (SF3).

2 **MEZCLAR**
EL CSV DEL IGN PONE MUNICIPIOS REALES; LAS FECHAS PASAN A SER FECHAS.

3 **ESCRIBIR**
18 TABLAS EN PARQUET, POR COLUMNAS, EN /DATALAKE/RAW.

4 **GUARDAR**
HDFS REPARTE BLOQUES EN DATANODES; EL NAMENODE LOS REGISTRA.

5 **LEER**
PYARROW, POLARS Y DUCKDB LEEN LO MISMO POR CAMINOS DISTINTOS.

6 **PREGUNTAR**
CLIENTES, PROVINCIAS, HORAS Y MESES: LAS PRIMERAS PREGUNTAS.

N

2026

EL HILO DE LA SESIÓN

PARQUET PERMITE LEER SÓLO LAS COLUMNAS QUE PIDE LA CONSULTA. EL PLAN LO DEMUESTRA ANTES DE EJECUTAR.

NOMBRE PRECIO

22 COLUMNAS

PLAN DE LA CONSULTA
LEE PARQUET: 2 DE 22 COLUMNAS
FILTRO POR PRECIO

¿Y SI SÓLO NECESITO DOS COLUMNAS?

OBSERVAR EL PLAN

DE VUELTA AL CAMPAMENTO, EL DOCTOR TERA ANOTA LO APRENDIDO: DE DÓNDE VIENEN LOS DATOS, DÓNDE VIVEN Y CÓMO PREGUNTARLES.

¡Y TODO ESTO, EN 2026! ¡QUÉ ÉPOCA TAN APASIONANTE!

2026

PREGUNTAS PARA INTERPRETAR LA EXPERIENCIA

SESIÓN 3: LOS PARQUET CRUZAN EL RÍO HASTA UN ALMACÉN DE OBJETOS COMPATIBLE CON S3.

S3

PARQUET

2026

LAS MISMAS TRES GUÍAS LEERÁN LOS PARQUET DESDE ALLÍ.

¡CONTINUARÁ...!

CONTINUACIÓN DEL CURSO

MISIONES DEL EXPLORADOR

- ☑ MIDE EL LAGO: TAMAÑO DEL DATASET, LÓGICO Y REPLICADO.
- ☑ COMPRUEBA QUE PYARROW, POLARS Y DUCKDB CUENTAN LO MISMO.
- ☑ RESPONDE LAS TRES PREGUNTAS: CLIENTE, PROVINCIA Y HORA.
- ☑ ENSEÑA EL PLAN: ¿QUÉ COLUMNAS LEE DE VERDAD?
- ☑ EXPLICA LAGO, ALMACÉN Y CATÁLOGO, Y LAS CAPAS RAW, SILVER Y GOLD.

REUNIÓN DE 5 MINUTOS CON EL PROFESOR
+ MEMORIA DE 1 O 2 PÁGINAS

EVIDENCIAS PARA LA SIGUIENTE SESIÓN