EL ALMACÉN DE LOS CUBOS

SESIÓN 3

AL OTRO LADO DEL RÍO, LA GENTE DE 2026 GUARDABA LOS DATOS APARTE: EN UN ALMACÉN DE OBJETOS.

¡LOS DATOS EN UN SITIO Y LAS MÁQUINAS QUE CALCULAN, EN OTRO!

S3

SPARK

2026

TRINO

PARQUET

¡CUAC! LOS MOTORES VAN, LEEN Y SE VUELVEN.

HDFS: DATOS Y CÓMPUTO JUNTOS

ALMACÉN Y CÓMPUTO SE DIMENSIONAN Y SE PAGAN POR SEPARADO.

DE UN SISTEMA DE FICHEROS A UN ALMACÉN DE OBJETOS

¡HOLA! SOY RUSTI. HABLO S3, COMO EL GRAN ALMACÉN DE LA NUBE. ¡Y SIN CUENTA DE AWS!

AWS

AMAZON S3, EN LA NUBE

RUSTFS

S3

LA API DE S3 ES UN IDIOMA: RUSTFS LA HABLA EN EL LABORATORIO.

RUSTFS: LA API DE S3 SIN UNA CUENTA DE AWS

TODO CLIENTE DE S3 NECESITA TRES DATOS. VAN EN VARIABLES AWS_*, FUERA DEL CÓDIGO.

SERVIDOR: HTTP://RUSTFS:9000
CREDENCIAL: TCDM_STUDENT ******
REGIÓN: US-EAST-1

AWS_ENDPOINT_URL
AWS_ACCESS_KEY_ID …
AWS_DEFAULT_REGION

2026

¿CON OTRO ALMACÉN? CAMBIA EL SOBRE, NO EL PROGRAMA.

S3

ENDPOINT Y CREDENCIALES

TRES MANERAS DE LLEGAR AL ALMACÉN: LA PALOMA BOTO3 LLEVA LAS PETICIONES DE UNA EN UNA; PYARROW Y POLARS CRUZAN EN EL FERRI S3FS; DUCKDB REMA EN SU CANOA, HTTPFS.

GET

BOTO3

S3

S3FS

PYARROW · POLARS

HTTPFS

LAS BIBLIOTECAS QUE HABLAN CON S3

LO ÚNICO QUE SE CREA ANTES DE ESCRIBIR ES EL CUBO (BUCKET): SU NOMBRE Y SU REGIÓN. SE HACE UNA VEZ.

¡NO HACEN FALTA! SÓLO SE CREA EL CUBO.

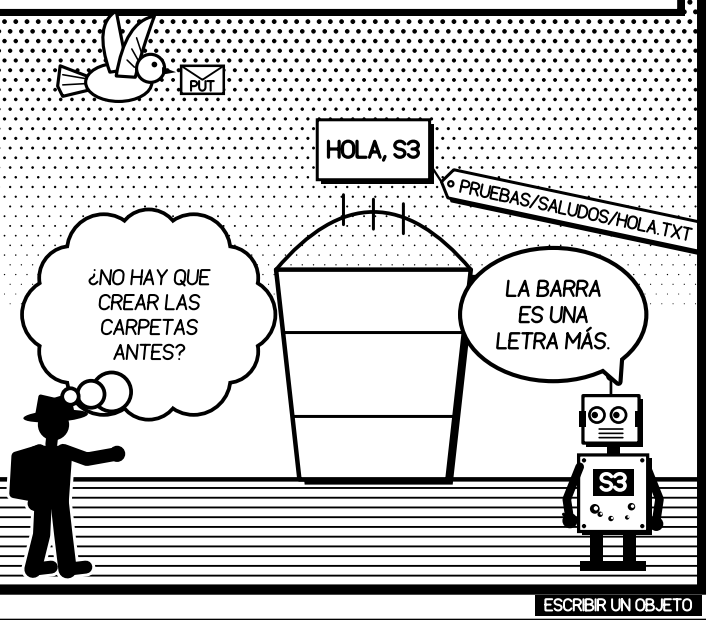
¿Y LAS CARPETAS?

TCDM-DATALAKE

S3

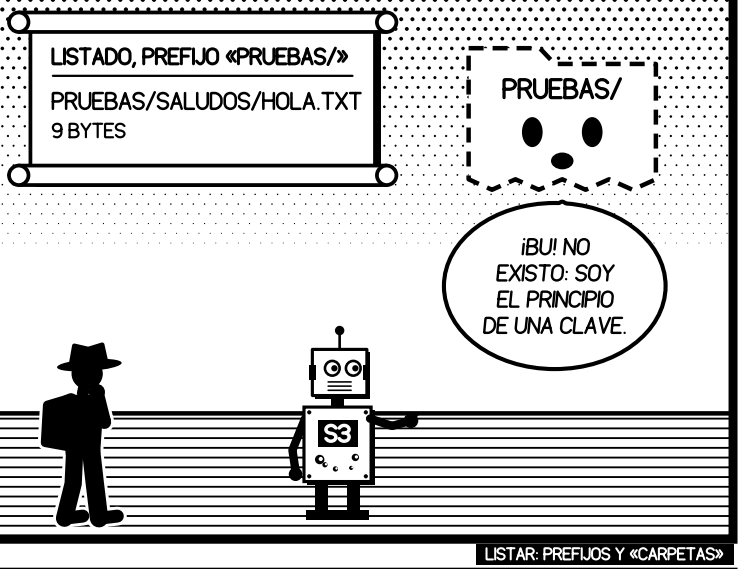
CREAR EL BUCKET

PUT: EL OBJETO ENTRA ENTERO, CON SU CLAVE. NO HAY QUE CREAR «PRUEBAS/» NI «SALUDOS/»: LAS BARRAS SON PARTE DE LA CLAVE.



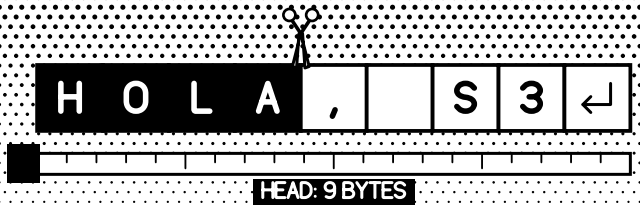
ESCRIBIR UN OBJETO

LISTAR ES LA ÚNICA FORMA DE SABER QUÉ HAY. CON DELIMITADOR «/», RUSTI AGRUPA LAS CLAVES HASTA LA BARRA: ASÍ SALEN LAS «CARPETAS».



LISTAR: PREFIJOS Y «CARPETAS»

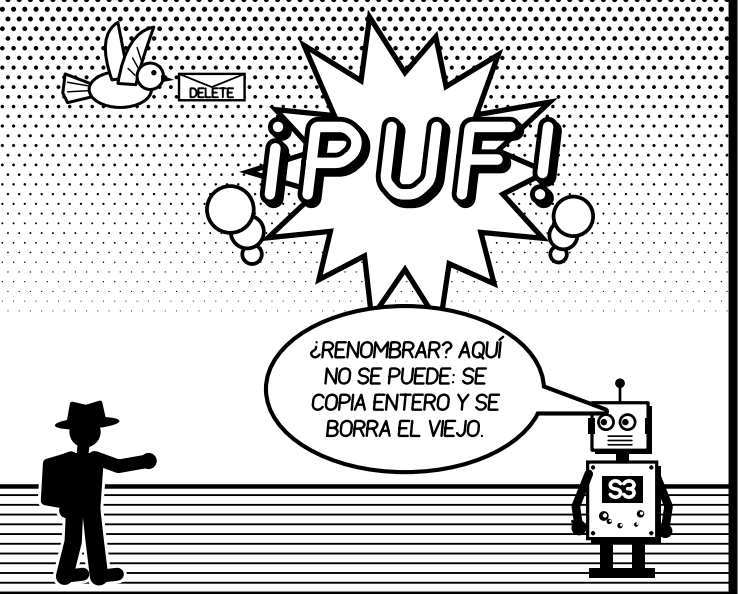
HEAD DICE CUÁNTO MIDE UN OBJETO SIN ABRIRLO. GET PUEDE PEDIR SÓLO UN TROZO: UN RANGO DE BYTES.





METADATOS Y LECTURA POR RANGO

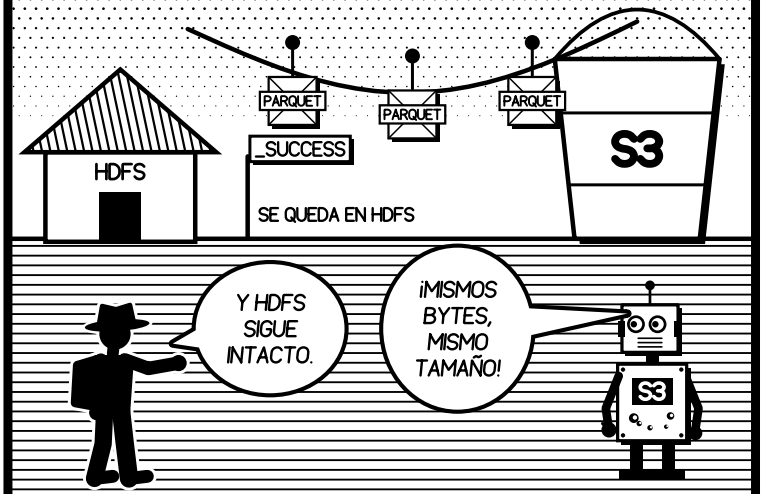
DELETE: AL BORRAR EL ÚNICO OBJETO QUE EMPEZABA POR «PRUEBAS/», EL PREFIJO DESAPARECE. NUNCA FUE UNA CARPETA.



BORRAR

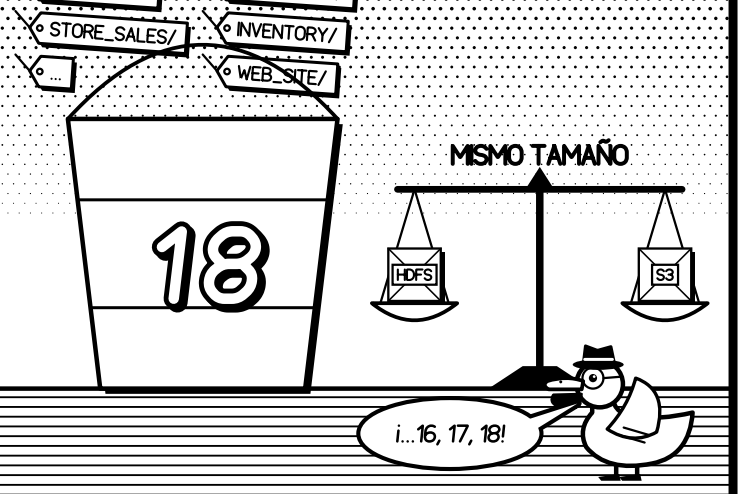
LA COPIA: CADA PARQUET VIAJA DE HDFS AL CUBO TAL CUAL, SIN PASAR POR EL DISCO.

/DATALAKE/RAW/TPCDS/ITEM/... → RAW/TPCDS/ITEM/...
LA CLAVE CONSERVA CAPA, FUENTE Y TABLA



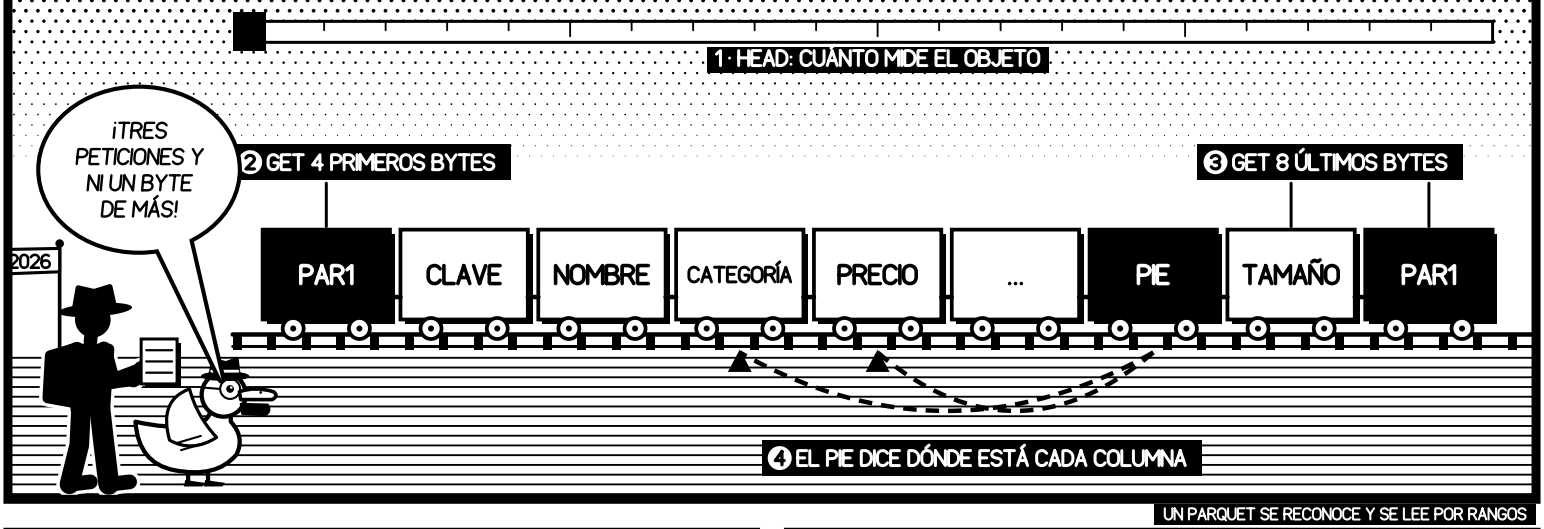
COPIAR RAW/TPCDS DE HDFS AL BUCKET

EN EL CUBO, UN PREFIJO POR TABLA: 18. MISMOS NOMBRES Y MISMOS TAMAÑOS QUE EN HDFS.



QUÉ HA QUEDADO EN EL BUCKET

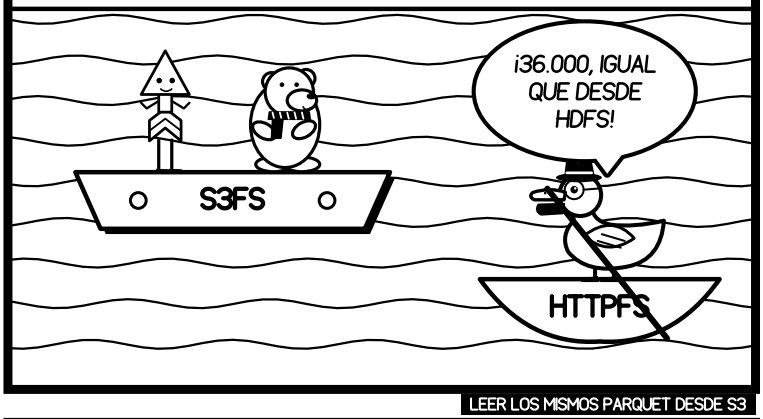
NINGÚN LECTOR SE FÍA DE LA EXTENSIÓN: UN PARQUET EMPIEZA Y ACABA CON PAR1. JUSTO ANTES DEL FINAL ESTÁ EL PIE, QUE DICE DÓNDE EMPIEZA CADA COLUMNA.



UN PARQUET SE RECONOCE Y SE LEE POR RANGOS

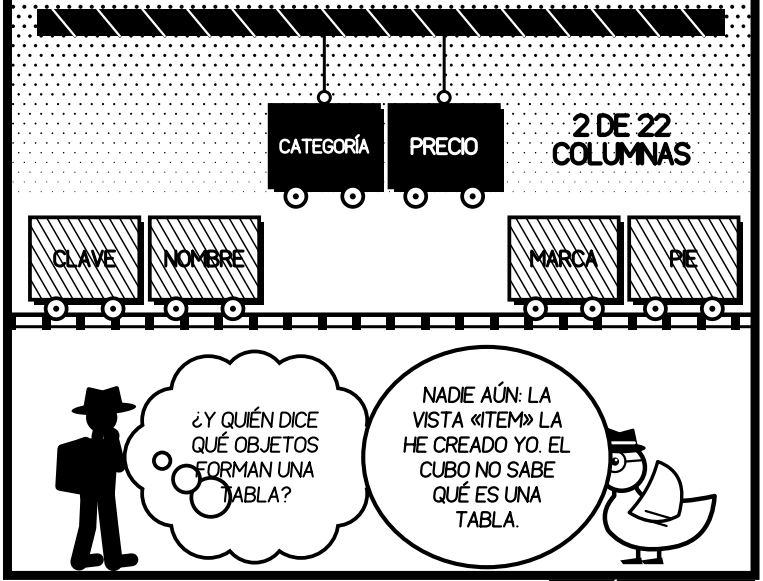
PYARROW Y POLARS LLEGAN POR S3FS; DUCKDB, POR HTTPFS. LAS CINCO CIFRAS COINCIDEN... Y SON LAS DE S2.

PYARROW	POLARS	DUCKDB
36.000 PRODUCTOS	36.000 PRODUCTOS	36.000 PRODUCTOS
POR S3FS	POR S3FS	POR HTTPFS



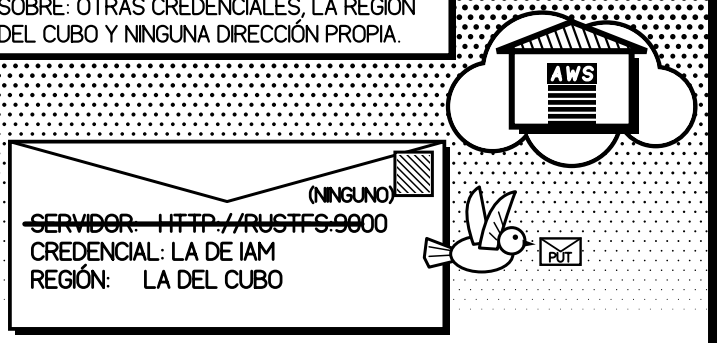
LEER LOS MISMOS PARQUET DESDE S3

DUCKDB LEE EL PIE Y PIDE SÓLO LOS RANGOS DE LAS DOS COLUMNAS QUE USA LA CONSULTA.



LEER SÓLO LO NECESARIO

PARA IR A AMAZON S3 SÓLO CAMBIA EL SOBRE: OTRAS CREDENCIALES, LA REGIÓN DEL CUBO Y NINGUNA DIRECCIÓN PROPIA.



EL CÓDIGO NO CAMBIA



DEL LABORATORIO A AMAZON S3

MISIONES DEL EXPLORADOR

- [x] ENSEÑA EL CUBO CON SUS 18 PREFIJOS DE TABLA.
- [x] DI CUÁNTOS PARQUET VIAJARON EN LA COPIA.
- [x] LEE PAR1 Y EL TAMAÑO DEL PIE SIN DESCARGAR.
- [x] LAS TRES LECTURAS DE ITEM: 36.000, COMO EN S2.
- [x] SEÑALA QUÉ CAMBIARÍA PARA USAR AMAZON S3.

REUNIÓN BREVE CON EL PROFESOR
+ MEMORIA DE 1 O 2 PÁGINAS

¡CONTINUARÁ! SESIÓN 4: SPARK, EL MOTOR QUE REPARTE EL TRABAJO

EVIDENCIAS PARA LA SIGUIENTE SESIÓN