Resumen de la sesión 4

Spark: de los Parquet a las consultas



Curso 2026/2027

Diego Sevilla
Departamento de Ingeniería y Tecnología de Computadores
Facultad de Informática · Universidad de Murcia

dsevilla@um.es

Qué vamos a repasar

La sesión 4 pone a **Spark** a trabajar sobre los Parquet de S2. Este resumen recorre el camino que sigue una consulta, de la lectura al reparto del trabajo:

- **DataFrames y expresiones**: leer, seleccionar, filtrar y calcular columnas, y entender por qué describir un cálculo no es ejecutarlo
- **Agrupar y unir**: qué representa cada fila antes y después de un `groupBy` o de un `join`
- **Spark SQL**: las mismas operaciones expresadas con vistas y consultas
- **Cómo se ejecuta**: el plan, las particiones, el *shuffle*, YARN y qué conviene guardar

> Quedan fuera de este resumen, pero están en el cuaderno: funciones de ventana, `rollup` y `cube`, tipos de join menos comunes, arrays y structs, y `spark-submit`

Los mismos datos, otro motor

S2 dejó las tablas TPC-DS como ficheros Parquet en HDFS, bajo `/datalake/raw/tpcds`. Spark lee **esos mismos ficheros**: no hace falta generar los datos otra vez ni cargarlos en una base de datos.

- Un **DataFrame** representa datos con columnas y tipos, junto con el plan para obtenerlos
- Se consulta con la API de DataFrames o con SQL, y las dos pasan por el mismo motor
- Primero se ejecuta en local, en el propio equipo del driver; después, YARN reparte las tareas entre ejecutores que corren en los DataNodes

> Cambia dónde se hace el cálculo; el significado de la consulta debe conservarse

DataFrames y expresiones

Leer, seleccionar, filtrar y calcular columnas

Leer Parquet y conocer el esquema

Con la sesión `spark` del cuaderno ya abierta:

```
from pyspark.sql import DataFrame
from pyspark.sql import functions as F

web_sales: DataFrame = spark.read.parquet("/datalake/raw/tpcds/web_sales")
item: DataFrame = spark.read.parquet("/datalake/raw/tpcds/item")
web_sales.printSchema()
```

Se lee un **directorio** de Parquet, no un fichero: Spark toma el esquema de los propios ficheros, y `printSchema()` muestra el nombre, el tipo y si admite nulos de cada columna.

Recuerda que una fila de `web_sales` es una **línea de venta**: un pedido con tres artículos ocupa tres filas.

Describir el cálculo todavía no lo ejecuta

```
pérdidas: DataFrame = web_sales.filter(
    F.col("ws_net_profit") < 0
).select("ws_order_number", "ws_net_profit")
```

Esta celda termina al instante y no muestra nada. Spark sólo ha **anotado en un plan** que queremos las líneas con beneficio negativo y dos de sus columnas. La variable `pérdidas` es un DataFrame, es decir, una descripción del cálculo, no una lista de filas traída a Python.

Mientras sólo encadenemos operaciones de este tipo, no se lee ningún dato de las ventas. Spark espera a que pidamos un resultado para decidir cómo calcularlo de la forma más económica.

> Las transformaciones describen qué calcular; una acción pide obtener un resultado

Transformaciones y acciones

Construyen otro plan	Ejecutan para obtener un resultado
`select`, `filter`, `withColumn`	`show(n)`: muestra unas filas
`groupBy(...).agg(...)`, `join`	`count()`: devuelve el número de filas
`orderBy`, `limit`, `spark.sql(...)`	`collect()`: trae todas las filas al driver
	`write.parquet(...)`: escribe el resultado

Una acción ejecuta el plan, pero no siempre recorre todo. `perdidas.show(5)` puede parar en cuanto encuentra cinco filas que cumplen el filtro; en cambio `perdidas.count()` debe revisar todos los datos, porque necesita el total. Si hay pocas coincidencias, incluso `show(5)` tendrá que buscar en muchas particiones.

Reserva `collect()` y `toPandas()` para resultados pequeños: traen todo a la memoria del driver.

Expresiones de columna

```
ventas = web_sales.select(
    "ws_order_number", F.col("ws_net_profit").alias("beneficio"),
    F.year("ws_sold_timestamp").alias("sold_year"))
con_perdida = web_sales.filter(
    F.col("ws_sold_timestamp").isNotNull() & (F.col("ws_net_profit") < 0))
clasificadas = web_sales.withColumn("resultado",
    F.when(F.col("ws_net_profit").isNull(), "desconocido")
     .when(F.col("ws_net_profit") < 0, "pérdida").otherwise("sin pérdida"))
```

- Ninguna de las tres modifica `web_sales`: cada una devuelve **otro DataFrame**. No recorremos filas con un bucle Python; describimos el cálculo y Spark lo reparte
- Con columnas se usan `&`, `|` y `~`, siempre entre paréntesis; las palabras `and`, `or` y `not` de Python no funcionan
- `filter` conserva las filas donde la condición es verdadera, y una comparación con `null` nunca lo es: por eso `isNull()` e `isNotNull()` se tratan aparte
- Conviene preferir las funciones integradas (`F.when`, `F.year`…): Spark las entiende y las optimiza. Una UDF de Python sirve para casos propios, pero añade coste y esconde su lógica al optimizador

Agrupar y unir

Qué representa cada fila antes y después del cálculo

`groupBy` y `agg`: beneficio por año

```
por_año: DataFrame = (
    web_sales.filter(F.col("ws_sold_timestamp").isNotNull())
    .groupBy(F.year("ws_sold_timestamp").alias("sold_year"))
    .agg(
        F.sum("ws_net_profit").alias("beneficio_neto"),
        F.countDistinct("ws_order_number").alias("pedidos"),
        F.count("*").alias("lineas_de_venta"),
    )
    .orderBy("sold_year")
)
por_año.show()
```

Antes del cálculo hay **una fila por línea de venta**; después, **una fila por año**. `groupBy` decide los grupos y `agg` calcula las medidas dentro de cada uno. Antes de escribir una agregación conviene preguntarse qué representa una fila del resultado.

Contar filas no es contar pedidos

Tres líneas de venta de dos pedidos (ejemplo ilustrativo):

Pedido	Artículo	Beneficio neto
100	A	8
100	B	`null`
101	C	−2

Expresión dentro de `agg`	Resultado	Qué significa
`F.count("*")`	3	Líneas de venta
`F.countDistinct("ws_order_number")`	2	Pedidos distintos
`F.count("ws_net_profit")`	2	Líneas con beneficio conocido
`F.sum("ws_net_profit")`	6	Suma de los beneficios conocidos

El `null` no cuenta como cero: `count("ws_net_profit")` lo ignora y `sum` lo salta. Y no hay que confundir `F.count( … )`, que construye una expresión dentro de `agg`, con `df.count()`, que ejecuta un recuento y devuelve un entero.

Filtrar grupos y ordenar un resultado

Clientes conocidos con más de cinco pedidos, de mayor a menor actividad:

```
clientes_activos: DataFrame = (
    web_sales.filter(F.col("ws_bill_customer_sk").isNotNull())
    .groupBy("ws_bill_customer_sk")
    .agg(F.countDistinct("ws_order_number").alias("pedidos"))
    .filter(F.col("pedidos") > 5)
    .orderBy(F.col("pedidos").desc(), "ws_bill_customer_sk")
    .limit(10)
)
```

Hay dos `filter` con papeles distintos. El primero se aplica **antes** de agrupar y elige líneas; el segundo, **después** de `agg`, elige grupos, igual que `HAVING` en SQL.

`orderBy` fija el orden y el desempate, para que el resultado sea repetible. `limit` recorta el resultado, pero no evita calcular todos los grupos antes.

`join`: añadir la categoría de cada venta

```
ventas_categoria: DataFrame = (
    web_sales.join(item, web_sales.ws_item_sk == item.i_item_sk, "inner")
    .select(F.year("ws_sold_timestamp").alias("sold_year"),
            "i_category", "ws_net_profit")
)
ventas_categoria.groupBy("sold_year", "i_category").agg(
    F.sum("ws_net_profit").alias("beneficio_neto")
).orderBy("sold_year", "i_category").show()
```

La condición `ws_item_sk = i_item_sk` enlaza cada línea de venta con la versión del artículo que se vendió. Con `inner` sólo se conservan las ventas que encuentran pareja; con `left` se conservarían todas, con la categoría vacía en las que no la encuentran.

Cuidado: si una clave encuentra varias filas al otro lado, la venta se repite una vez por cada coincidencia, y una suma posterior inflaría el importe. Las claves `_sk` sirven para unir, no son nombres de clientes ni de provincias.

Vistas y Spark SQL

Las mismas operaciones, expresadas con SQL

Dar un nombre SQL a un DataFrame

```
web_sales.createOrReplaceTempView("web_sales")

muestra: DataFrame = spark.sql("""
    SELECT ws_order_number, ws_net_profit
    FROM web_sales
    WHERE ws_net_profit < 0
""")
muestra.show(5)
```

`createOrReplaceTempView` asocia un nombre SQL al DataFrame. La vista pertenece a la **sesión de Spark**: no crea una tabla persistente ni copia los Parquet, igual que las vistas de DuckDB en S2.

`spark.sql( ... )` devuelve a su vez un DataFrame, así que podemos seguir transformándolo con la API. SQL y DataFrames son dos formas de pedir lo mismo al mismo planificador.

La agregación anual, ahora en SQL

```
por_año_sql: DataFrame = spark.sql("""
    SELECT year(ws_sold_timestamp) AS sold_year,
           sum(ws_net_profit) AS beneficio_neto,
           count(DISTINCT ws_order_number) AS pedidos,
           count(*) AS lineas_de_venta
    FROM web_sales
    WHERE ws_sold_timestamp IS NOT NULL
    GROUP BY year(ws_sold_timestamp)
    ORDER BY sold_year
""")
por_año_sql.show()
```

Es el mismo filtro, los mismos grupos y las mismas medidas que `por_año`, y debe dar los mismos valores tanto en local como sobre YARN: cambia dónde se calcula, no el resultado.

> Para pensar: ¿por qué en cada año `pedidos` es menor que `lineas_de_venta`? ¿Qué pasaría si sumáramos `ws_ext_sales_price` en lugar de `ws_net_profit`?

Cómo se ejecuta

Leer el plan y reconocer dónde se mueve el dato

`explain`: mirar el trabajo que hemos pedido

```
web_sales.select("ws_order_number", "ws_net_profit") \
    .filter(F.col("ws_net_profit") > 0).explain("formatted")
```

```
(1) Scan parquet
Output [2]: [ws_order_number, ws_net_profit]
PushedFilters: [IsNotNull(ws_net_profit), GreaterThan(ws_net_profit,0)]
ReadSchema: struct<ws_order_number:bigint,ws_net_profit:decimal(7,2)>
(3) Filter   Condition : (isnotnull(ws_net_profit) AND (ws_net_profit > 0))
```

`ReadSchema` dice que sólo se leen **dos columnas** de las que tiene `web_sales`, y `PushedFilters` que el filtro se entrega al lector de Parquet para descartar datos pronto. Salida abreviada. En planes con agregaciones o uniones aparecerá también `Exchange`, una redistribución de datos entre particiones.

`explain` no calcula el resultado; para ver tiempos y tareas se mira la Spark UI mientras se ejecuta una acción.

Particiones y *shuffle*

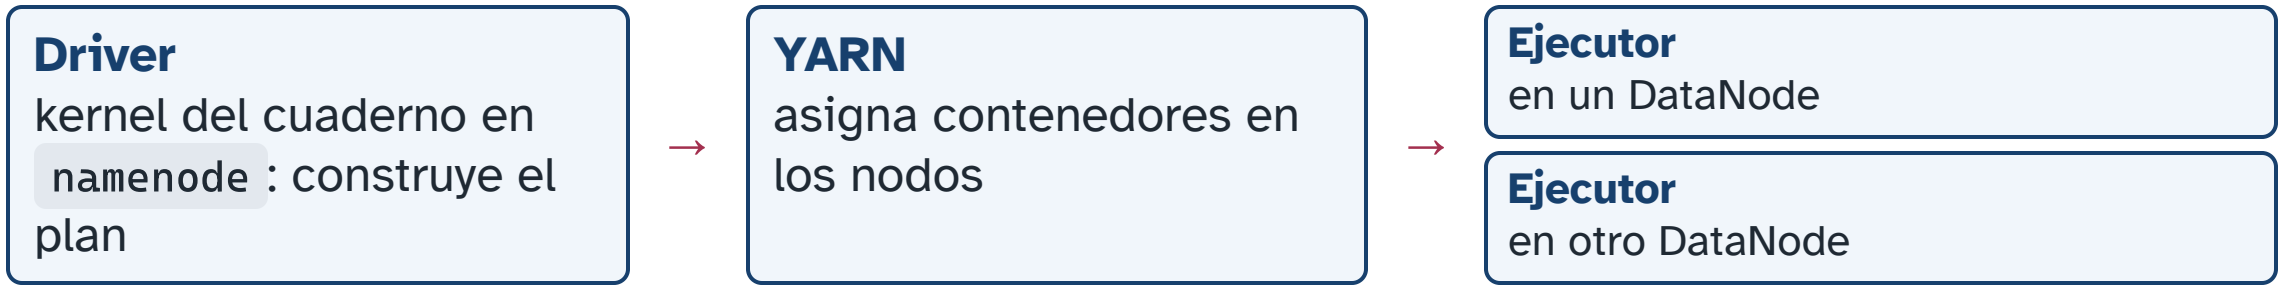
Una **partición de ejecución** es el trozo de un DataFrame que procesa una tarea. Operaciones como `select` o `filter` trabajan sobre cada partición por separado, sin necesitar filas de las demás.

Una agregación por clave es distinta: las filas de una misma clave pueden estar repartidas en muchas particiones, y hay que reunirlas antes de sumar. Ese intercambio de datos entre particiones, a través de la red, es el ***shuffle***, y suele ser lo más caro de una consulta.

Un `join` puede obligar a redistribuir los dos lados. Si uno de ellos es pequeño, un *broadcast join* lo copia entero a cada ejecutor y evita mover el grande.

Un fichero Parquet, un bloque de HDFS y una partición de ejecución **no son lo mismo**, y tener tres ejecutores no garantiza tres partes iguales: importa el reparto real de las filas.

Driver, ejecutores y YARN



En `local[2]` todo ocurre en el equipo del driver, con dos hilos. Al cambiar el `master` a YARN, **el driver sigue en `namenode`**, pero los ejecutores son procesos reales en los DataNodes, que leen los Parquet de HDFS.

Una acción lanza un trabajo (*job*), dividido en etapas (*stages*) y tareas (*tasks*), y cada tarea procesa una partición. El informe de hosts de S4 muestra en qué DataNode se procesó cada partición y cuántas filas tenía.

Reutilizar con `cache` y repartir con `repartition`

- `cache()` marca un DataFrame para guardarlo en memoria cuando una acción lo calcule. Las acciones siguientes lo reutilizan en vez de recalcularlo desde HDFS; `unpersist()` libera esa memoria. Sólo compensa si se usa **más de una vez**
- `repartition(n)` redistribuye las filas en `n` particiones mediante un *shuffle* completo. Es útil, por ejemplo, para equilibrar el trabajo antes de un `join`
- `coalesce(n)` reduce el número de particiones sin un *shuffle* completo: es más barato, pero puede dejar particiones desiguales

Con `getNumPartitions()` se comprueba cuántas particiones tiene un DataFrame antes y después de cada operación.

> Ninguna de las tres cambia el resultado de la consulta, sólo cómo se reparte y se reutiliza el trabajo

Guardar un resultado

```
por_año.coalesce(1).write.mode("overwrite").parquet(
    "/user/luser/s4/resumen-beneficio-anual"
)
```

La escritura crea un **directorio** con uno o varios ficheros Parquet, no un único fichero: Spark escribe un fichero por partición. `mode("overwrite")` sustituye lo que hubiera en esa ruta.

`por_año` tiene una fila por año, así que `coalesce(1)` evita dejar muchos ficheros diminutos, el problema de los **ficheros pequeños**, que ralentiza las lecturas posteriores.

Reducir a una sola partición sólo es apropiado para resultados pequeños. Con un resultado grande, una única tarea tendría que escribir todo y se perdería el paralelismo.

Lo que hay que llevarse de S4

- Spark lee los **mismos Parquet** de S2; un DataFrame es una descripción del cálculo, y sólo una **acción** lo ejecuta
- Antes de escribir una consulta hay que saber qué representa una fila, qué mide cada columna y por qué clave se agrupa: `count(*)` cuenta líneas, `countDistinct(pedido)` cuenta pedidos, y una suma de ventas no es una suma de beneficios
- Una unión puede **multiplicar filas**, y los `null` no son ceros
- La API de DataFrames y SQL dicen lo mismo; `explain` enseña cómo intenta resolverlo Spark y dónde hay **shuffle**
- En YARN el driver sigue en `namenode` y los ejecutores trabajan en los DataNodes: se reparten **tareas sobre particiones**, no filas por igual
- Un resultado se guarda como directorio de Parquet; conviene evitar los ficheros pequeños

> **En S5** Spark deja de leer sólo `raw` y escribe datos *silver* y un producto *gold*, con convenciones de nombres, controles de calidad y particionado físico