

# Tecnologías de Computación de Datos Masivos

## Presentación de la asignatura

**Curso 2026/2027**

Diego Sevilla

Departamento de Ingeniería y Tecnología de Computadores  
Facultad de Informática · Universidad de Murcia

dsevilla@um.es



# Tecnologías de Computación de Datos Masivos

---

|                        |                                         |
|------------------------|-----------------------------------------|
| <b>Curso académico</b> | 2026/2027                               |
| <b>Titulación</b>      | Máster en Big Data                      |
| <b>Cuatrimestre</b>    | Primero                                 |
| <b>Curso</b>           | Primero                                 |
| <b>Carácter</b>        | Obligatoria                             |
| <b>Créditos ECTS</b>   | 4,5                                     |
| <b>Departamento</b>    | Ingeniería y Tecnología de Computadores |

# Profesor y horario

---

| Actividad | Profesor   | Horario             | Aula     |
|-----------|------------|---------------------|----------|
| Teoría    | D. Sevilla | Jueves, 17:30–19:00 | Lab. 2.4 |
| Sesiones  | D. Sevilla | Jueves, 19:00–20:30 | Lab. 2.4 |

## Tutorías y contacto

| Profesor   | Tutorías                                          | Contacto                                                    |
|------------|---------------------------------------------------|-------------------------------------------------------------|
| D. Sevilla | Miércoles, 11:00–14:00<br>y tutorías electrónicas | <code>dsevilla@um.es</code><br>868 88 7571<br>Despacho 3.31 |

# Sesiones 1-4 · Fundamentos y motores

---

- **S1 · Entorno Hadoop con contenedores**
  - Big Data, modelo MapReduce y procesamiento distribuido
  - Clúster local, HDFS, YARN, NameNode, DataNodes y NodeManagers
- **S2 · TPC-DS en Parquet sobre HDFS**
  - TPC-DS SF1 combinado de forma determinista con municipios del INE
  - Rutas, esquemas y lectura mediante WebHDFS, PyArrow, Polars y DuckDB
- **S3 · Data lake sobre almacenamiento S3-compatible**
  - Objetos, buckets y prefijos frente a ficheros y bloques HDFS
  - RustFS, API S3 y lectura de los mismos Parquet con distintas herramientas
- **S4 · Spark como motor distribuido**
  - DataFrames, transformaciones, acciones, joins, ventanas y planes
  - Ejecución local y sobre YARN, particiones, driver y ejecutores

## Sesiones 5–8 • Del data lake al lakehouse

---

- **S5 • Arquitectura medallion y particionado físico**
  - Capas *raw*, *silver* y *gold*, contratos de datos y validación
  - Particiones por fecha, poda de particiones y comparación de planes
- **S6 • Hive Metastore, tablas Hive y Trino**
  - Tablas externas y administradas, registro y descubrimiento de particiones
  - Un metastore compartido por Spark y Trino, con estadísticas `ANALYZE`
- **S7 • Iceberg, evolución y optimización**
  - Snapshots, evolución de esquema, consultas históricas y particionado
  - Compactación, ordenación física, estadísticas y Z-order
- **S8 • Ingesta continua con Structured Streaming**
  - Micro-lotes simulados, checkpoints y `foreachBatch`
  - `MERGE INTO` incremental en *silver* y *gold* con tablas Iceberg

# Planificación del curso

---

| Fecha         | Sesión                                                             |
|---------------|--------------------------------------------------------------------|
| 01/10         | Introducción a la asignatura                                       |
| 08/10         | S1 · Entorno Hadoop con contenedores                               |
| 22/10         | S2 · Exploración de TPC-DS en Parquet sobre HDFS                   |
| 29/10         | S3 · Un data lake sobre almacenamiento S3-compatible               |
| 05/11         | S4 · Spark como motor de procesamiento distribuido                 |
| 12/11         | S5 · Buenas prácticas de data lake y particionado físico           |
| 18/11 y 19/11 | S6 · Hive Metastore, tablas Hive y Trino                           |
| 26/11         | S7 · Iceberg: del data lake al lakehouse, evolución y optimización |
| 03/12         | S8 · Ingesta continua con Spark Structured Streaming               |

# Calendario de las sesiones

## OCTUBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    |    |    | 1  | 2  | 3  | 4  |
| 5  | 6  | 7  | 8  | 9  | 10 | 11 |
| 12 | 13 | 14 | 15 | 16 | 17 | 18 |
| 19 | 20 | 21 | 22 | 23 | 24 | 25 |
| 26 | 27 | 28 | 29 | 30 | 31 |    |

## NOVIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    |    |    |    |    |    | 1  |
| 2  | 3  | 4  | 5  | 6  | 7  | 8  |
| 9  | 10 | 11 | 12 | 13 | 14 | 15 |
| 16 | 17 | 18 | 19 | 20 | 21 | 22 |
| 23 | 24 | 25 | 26 | 27 | 28 | 29 |
| 30 |    |    |    |    |    |    |

## DICIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    | 1  | 2  | 3  | 4  | 5  | 6  |
| 7  | 8  | 9  | 10 | 11 | 12 | 13 |
| 14 | 15 | 16 | 17 | 18 | 19 | 20 |
| 21 | 22 | 23 | 24 | 25 | 26 | 27 |
| 28 | 29 | 30 | 31 |    |    |    |

## CONTENIDO DE LA SEMANA

01/10 Introducción a la asignatura  
08/10 S1 · Entorno Hadoop  
12/10 (sin clase)  
22/10 S2 · Parquet TPC-DS en HDFS  
29/10 S3 · Data lake S3-compatible

05/11 S4 · Spark y YARN  
12/11 S5 · Medallion y particionado  
18-19/11 S6 · Hive Metastore y Trino  
26/11 S7 · Iceberg y optimización

03/12 S8 · Streaming con Spark

# Un mismo recorrido de datos durante las sesiones

Las sesiones trabajan sobre un dataset común y reproducible:

```
TPC-DS SF1                      Relación de municipios del INE
(ventas, clientes, fechas)      (municipio y provincia españoles)
      \                          /
      \ cruce determinista /
      ↓
/datalake/raw/tpcds en HDFS
Parquet con ciudades y provincias españolas
      ↓
S3 -> Spark/YARN -> silver/gold -> Hive/Trino -> Iceberg/streaming
```

S2 realiza la descarga, normalización y materialización; las sesiones posteriores consumen el estado que deja el notebook anterior. El CI ejecuta esos mismos notebooks y comprueba sus salidas, mientras que el arranque de contenedores queda como preparación del entorno.

# Evaluación

---

## Teoría • 30 %

- Examen teórico tipo test

## Sesiones • 70 %

- Documentación de las sesiones
- Entrevista final

**Hay que superar cada parte por separado.**

# Cómo se revisan las sesiones prácticas

---

Cada guion de sesión termina con una sección **«Evidencias para la siguiente sesión»** que indica qué preparar.

En una sesión posterior, cada estudiante tiene una **reunión individual breve** (unos minutos) con el profesor para revisarlas:

- **En el ordenador:** el entorno funcionando y las evidencias pedidas (clúster arrancado, órdenes ejecutadas, interfaces web)
- **Por escrito:** una memoria breve (una o dos páginas) que explique lo realizado, no sólo capturas de pantalla

Este esquema se repite en todas las sesiones prácticas del curso.

# Bibliografía recomendada

---

## Referencias principales

- Tom White, *Hadoop: The Definitive Guide*, 4.ª ed., O'Reilly, 2015
- Bill Chambers y Matei Zaharia, *Spark: The Definitive Guide*, O'Reilly, 2018
- Holden Karau, Andy Konwinski, Patrick Wendell y Matei Zaharia, *Learning Spark*, O'Reilly, 2015
- Fabian Hueske y Vasiliki Kalavri, *Stream Processing with Apache Flink*, O'Reilly, 2019

## Otras referencias

- Petar Zečević y Marko Bonaci, *Spark in Action*, Manning, 2017
- Holden Karau y Rachel Warren, *High Performance Spark*, O'Reilly, 2017
- Sandy Ryza, Uri Laserson, Sean Owen y Josh Wills, *Advanced Analytics with Spark*, O'Reilly, 2017

# Repositorio de la asignatura

---

- Guiones de sesiones, materiales e información adicional
- Repositorio público: <https://github.com/dsevilla/tcdm-public>
- Rama del curso: **26-27**

```
$ git clone https://github.com/dsevilla/tcdm-public.git  
$ cd tcdm-public  
$ git switch 26-27
```

Los notebooks podrán ejecutarse localmente o en Google Colab y guardarse en Drive o en un repositorio propio.