

# Tecnologías de Computación de Datos Masivos

Presentación de la asignatura

Curso 2026/2027

Diego Sevilla

Departamento de Ingeniería y Tecnología de Computadores  
Facultad de Informática · Universidad de Murcia

dsevilla@um.es



# Tecnologías de Computación de Datos Masivos

---

|                        |                                         |
|------------------------|-----------------------------------------|
| <b>Curso académico</b> | 2026/2027                               |
| <b>Titulación</b>      | Máster en Big Data                      |
| <b>Cuatrimestre</b>    | Primero                                 |
| <b>Curso</b>           | Primero                                 |
| <b>Carácter</b>        | Obligatoria                             |
| <b>Créditos ECTS</b>   | 4,5                                     |
| <b>Departamento</b>    | Ingeniería y Tecnología de Computadores |

# Profesor y horario

---

| Actividad | Profesor   | Horario             | Aula     |
|-----------|------------|---------------------|----------|
| Teoría    | D. Sevilla | Jueves, 17:30–19:00 | Lab. 2.4 |
| Sesiones  | D. Sevilla | Jueves, 19:00–20:30 | Lab. 2.4 |

## Tutorías y contacto

| Profesor   | Tutorías                                          | Contacto                                                                           |
|------------|---------------------------------------------------|------------------------------------------------------------------------------------|
| D. Sevilla | Miércoles, 11:00–14:00<br>y tutorías electrónicas | <a href="mailto:dsevilla@um.es">dsevilla@um.es</a><br>868 88 7571<br>Despacho 3.31 |

# Sesiones 1-4 · Fundamentos y motores

---

- **S1 · Entorno Hadoop con contenedores**
  - Big Data, modelo MapReduce y procesamiento distribuido
  - Clúster local, HDFS, YARN, NameNode, DataNodes y NodeManagers
- **S2 · TPC-DS en Parquet sobre HDFS**
  - TPC-DS SF1 combinado de forma determinista con municipios del INE
  - Rutas, esquemas y lectura mediante WebHDFS, PyArrow, Polars y DuckDB
- **S3 · Data lake sobre almacenamiento S3-compatible**
  - Objetos, buckets y prefijos frente a ficheros y bloques HDFS
  - RustFS, API S3 y lectura de los mismos Parquet con distintas herramientas
- **S4 · Spark como motor distribuido**
  - DataFrames, transformaciones, acciones, joins, ventanas y planes
  - Ejecución local y sobre YARN, particiones, driver y ejecutores

# Sesiones 5–8 · Del data lake al lakehouse

---

- **S5 · Arquitectura medallion y particionado físico**
  - Capas *raw*, *silver* y *gold*, contratos de datos y validación
  - Particiones por fecha, poda de particiones y comparación de planes
- **S6 · Hive Metastore, tablas Hive y Trino**
  - Tablas externas y administradas, registro y descubrimiento de particiones
  - Un metastore compartido por Spark y Trino, con estadísticas `ANALYZE`
- **S7 · Iceberg, evolución y optimización**
  - Snapshots, evolución de esquema, consultas históricas y particionado
  - Compactación, ordenación física, estadísticas y Z-order
- **S8 · Ingesta continua con Structured Streaming**
  - Micro-lotes simulados, checkpoints y `foreachBatch`
  - `MERGE INTO` incremental en *silver* y *gold* con tablas Iceberg

# Planificación del curso

---

| Fecha         | Sesión                                                             |
|---------------|--------------------------------------------------------------------|
| 01/10         | Introducción a la asignatura                                       |
| 08/10         | S1 · Entorno Hadoop con contenedores                               |
| 22/10         | S2 · Exploración de TPC-DS en Parquet sobre HDFS                   |
| 29/10         | S3 · Un data lake sobre almacenamiento S3-compatible               |
| 05/11         | S4 · Spark como motor de procesamiento distribuido                 |
| 12/11         | S5 · Buenas prácticas de data lake y particionado físico           |
| 18/11 y 19/11 | S6 · Hive Metastore, tablas Hive y Trino                           |
| 26/11         | S7 · Iceberg: del data lake al lakehouse, evolución y optimización |
| 03/12         | S8 · Ingesta continua con Spark Structured Streaming               |

# Calendario de las sesiones

## OCTUBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    |    |    | 1  | 2  | 3  | 4  |
| 5  | 6  | 7  | 8  | 9  | 10 | 11 |
| 12 | 13 | 14 | 15 | 16 | 17 | 18 |
| 19 | 20 | 21 | 22 | 23 | 24 | 25 |
| 26 | 27 | 28 | 29 | 30 | 31 |    |

## NOVIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    |    |    |    |    |    | 1  |
| 2  | 3  | 4  | 5  | 6  | 7  | 8  |
| 9  | 10 | 11 | 12 | 13 | 14 | 15 |
| 16 | 17 | 18 | 19 | 20 | 21 | 22 |
| 23 | 24 | 25 | 26 | 27 | 28 | 29 |
| 30 |    |    |    |    |    |    |

## DICIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    | 1  | 2  | 3  | 4  | 5  | 6  |
| 7  | 8  | 9  | 10 | 11 | 12 | 13 |
| 14 | 15 | 16 | 17 | 18 | 19 | 20 |
| 21 | 22 | 23 | 24 | 25 | 26 | 27 |
| 28 | 29 | 30 | 31 |    |    |    |

## CONTENIDO DE LA SEMANA

01/10 Introducción a la asignatura  
08/10 S1 · Entorno Hadoop  
12/10 (sin clase)  
22/10 S2 · Parquet TPC-DS en HDFS  
29/10 S3 · Data lake S3-compatible

05/11 S4 · Spark y YARN  
12/11 S5 · Medallion y particionado  
18-19/11 S6 · Hive Metastore y Trino  
26/11 S7 · Iceberg y optimización

03/12 S8 · Streaming con Spark

# Un mismo recorrido de datos durante las sesiones

Las sesiones trabajan sobre un dataset común y reproducible:

```
TPC-DS SF1                      Relación de municipios del INE
(ventas, clientes, fechas)      (municipio y provincia españoles)
      \                          /
      \ cruce determinista /
      ↓
/datalake/raw/tpcds en HDFS
Parquet con ciudades y provincias españolas
      ↓
S3 -> Spark/YARN -> silver/gold -> Hive/Trino -> Iceberg/streaming
```

S2 realiza la descarga, normalización y materialización; las sesiones posteriores consumen el estado que deja el notebook anterior. El CI ejecuta esos mismos notebooks y comprueba sus salidas, mientras que el arranque de contenedores queda como preparación del entorno

# Evaluación

---

## Teoría · 50 %

- Examen teórico tipo test

## Sesiones · 50 %

- Documentación de las sesiones
- Entrevista final

**Hay que superar cada parte por separado**

# Cómo se revisan las sesiones prácticas

---

Cada guion de sesión termina con una sección **«Evidencias para la siguiente sesión»** que indica qué preparar

En una sesión posterior, cada estudiante tiene una **reunión individual breve** (unos minutos) con el profesor para revisarlas:

- **En el ordenador:** el entorno funcionando y las evidencias pedidas (clúster arrancado, órdenes ejecutadas, interfaces web)
- **Por escrito:** una memoria breve (una o dos páginas) que explique lo realizado, no sólo capturas de pantalla

Este esquema se repite en todas las sesiones prácticas del curso

# Bibliografía recomendada

---

## Referencias principales

- Tom White, *Hadoop: The Definitive Guide*, 4.<sup>a</sup> ed., O'Reilly, 2015
- Bill Chambers y Matei Zaharia, *Spark: The Definitive Guide*, O'Reilly, 2018
- Holden Karau, Andy Konwinski, Patrick Wendell y Matei Zaharia, *Learning Spark*, O'Reilly, 2015
- Fabian Hueske y Vasiliki Kalavri, *Stream Processing with Apache Flink*, O'Reilly, 2019

## Otras referencias

- Petar Zečević y Marko Bonaći, *Spark in Action*, Manning, 2017
- Holden Karau y Rachel Warren, *High Performance Spark*, O'Reilly, 2017
- Sandy Ryza, Uri Laserson, Sean Owen y Josh Wills, *Advanced Analytics with Spark*, O'Reilly, 2017

# Repositorio de la asignatura

---

- Guiones de sesiones, materiales e información adicional
- Repositorio público: <https://github.com/dsevilla/tcdm-public>
- Rama del curso: **26-27**

```
$ git clone --depth 1 --branch 26-27 \
    https://github.com/dsevilla/tcdm-public.git \
    ~/tcdm-public
$ cd ~/tcdm-public
$ git switch 26-27
```

En este caso, como los notebooks requieren el clúster funcionando, no se pueden ejecutar en Colab. Se pueden ejecutar en Visual Studio Code, por ejemplo, conectando con el servidor Jupyter de dentro del clúster