

Tecnologías de Computación de Datos Masivos

Presentación de la asignatura

Curso 2026/2027

Diego Sevilla

Departamento de Ingeniería y Tecnología de Computadores
Facultad de Informática · Universidad de Murcia

dsevilla@um.es



Tecnologías de Computación de Datos Masivos

Curso académico	2026/2027
Titulación	Máster en Big Data
Cuatrimestre	Primero
Curso	Primero
Carácter	Obligatoria
Créditos ECTS	4,5
Departamento	Ingeniería y Tecnología de Computadores

Profesor y horario

Actividad	Profesor	Horario	Aula
Teoría	D. Sevilla	Jueves, 17:30–19:00	Lab. 2.4
Sesiones	D. Sevilla	Jueves, 19:00–20:30	Lab. 2.4

Tutorías y contacto

Profesor	Tutorías	Contacto
D. Sevilla	Miércoles, 11:00–14:00 y tutorías electrónicas	<code>dsevilla@um.es</code> 868 88 7571 Despacho 3.31

Sesiones 1-4 · Fundamentos y motores

- **S1 · Entorno Hadoop con contenedores**
 - Big Data, modelo MapReduce y procesamiento distribuido
 - Clúster local, HDFS, YARN, NameNode, DataNodes y NodeManagers
- **S2 · TPC-DS en Parquet sobre HDFS**
 - TPC-DS SF1 combinado de forma determinista con municipios del INE
 - Rutas, esquemas y lectura mediante WebHDFS, PyArrow, Polars y DuckDB
- **S3 · Data lake sobre almacenamiento S3-compatible**
 - Objetos, buckets y prefijos frente a ficheros y bloques HDFS
 - RustFS, API S3 y lectura de los mismos Parquet con distintas herramientas
- **S4 · Spark como motor distribuido**
 - DataFrames, transformaciones, acciones, joins, ventanas y planes
 - Ejecución local y sobre YARN, particiones, driver y ejecutores

Sesiones 5–8 • Del data lake al lakehouse

- **S5 • Arquitectura medallion y particionado físico**
 - Capas *raw*, *silver* y *gold*, contratos de datos y validación
 - Particiones por fecha, poda de particiones y comparación de planes
- **S6 • Hive Metastore, tablas Hive y Trino**
 - Tablas externas y administradas, registro y descubrimiento de particiones
 - Un metastore compartido por Spark y Trino, con estadísticas `ANALYZE`
- **S7 • Iceberg, evolución y optimización**
 - Snapshots, evolución de esquema, consultas históricas y particionado
 - Compactación, ordenación física, estadísticas y Z-order
- **S8 • Ingesta continua con Structured Streaming**
 - Micro-lotes simulados, checkpoints y `foreachBatch`
 - `MERGE INTO` incremental en *silver* y *gold* con tablas Iceberg

Planificación del curso

Fecha	Sesión
01/10	Introducción a la asignatura
08/10	S1 · Entorno Hadoop con contenedores
22/10	S2 · Exploración de TPC-DS en Parquet sobre HDFS
29/10	S3 · Un data lake sobre almacenamiento S3-compatible
05/11	S4 · Spark como motor de procesamiento distribuido
12/11	S5 · Buenas prácticas de data lake y particionado físico
18/11 y 19/11	S6 · Hive Metastore, tablas Hive y Trino
26/11	S7 · Iceberg: del data lake al lakehouse, evolución y optimización
03/12	S8 · Ingesta continua con Spark Structured Streaming

Calendario de las sesiones

OCTUBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
			1	2	3	4
5	6	7	8	9	10	11
12	13	14	15	16	17	18
19	20	21	22	23	24	25
26	27	28	29	30	31	

NOVIEMBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
						1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	29
30						

DICIEMBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
	1	2	3	4	5	6
7	8	9	10	11	12	13
14	15	16	17	18	19	20
21	22	23	24	25	26	27
28	29	30	31			

CONTENIDO DE LA SEMANA

01/10 Introducción a la asignatura
08/10 S1 · Entorno Hadoop
12/10 (sin clase)
22/10 S2 · Parquet TPC-DS en HDFS
29/10 S3 · Data lake S3-compatible

05/11 S4 · Spark y YARN
12/11 S5 · Medallion y particionado
18-19/11 S6 · Hive Metastore y Trino
26/11 S7 · Iceberg y optimización

03/12 S8 · Streaming con Spark

Un mismo recorrido de datos durante las sesiones

Las sesiones trabajan sobre un dataset común y reproducible:

```
TPC-DS SF1                      Relación de municipios del INE
(ventas, clientes, fechas)      (municipio y provincia españoles)
      \                          /
      \ cruce determinista /
      ↓
/datalake/raw/tpcds en HDFS
Parquet con ciudades y provincias españolas
      ↓
S3 -> Spark/YARN -> silver/gold -> Hive/Trino -> Iceberg/streaming
```

S2 realiza la descarga, normalización y materialización; las sesiones posteriores consumen el estado que deja el notebook anterior. El CI ejecuta esos mismos notebooks y comprueba sus salidas, mientras que el arranque de contenedores queda como preparación del entorno.

Evaluación

Teoría • 30 %

- Examen teórico tipo test

Sesiones • 70 %

- Documentación de las sesiones
- Entrevista final

Hay que superar cada parte por separado.

Cómo se revisan las sesiones prácticas

Cada guion de sesión termina con una sección **«Evidencias para la siguiente sesión»** que indica qué preparar.

En una sesión posterior, cada estudiante tiene una **reunión individual breve** (unos minutos) con el profesor para revisarlas:

- **En el ordenador:** el entorno funcionando y las evidencias pedidas (clúster arrancado, órdenes ejecutadas, interfaces web)
- **Por escrito:** una memoria breve (una o dos páginas) que explique lo realizado, no sólo capturas de pantalla

Este esquema se repite en todas las sesiones prácticas del curso.

Bibliografía recomendada

Referencias principales

- Tom White, *Hadoop: The Definitive Guide*, 4.^a ed., O'Reilly, 2015
- Bill Chambers y Matei Zaharia, *Spark: The Definitive Guide*, O'Reilly, 2018
- Holden Karau, Andy Konwinski, Patrick Wendell y Matei Zaharia, *Learning Spark*, O'Reilly, 2015
- Fabian Hueske y Vasiliki Kalavri, *Stream Processing with Apache Flink*, O'Reilly, 2019

Otras referencias

- Petar Zečević y Marko Bonaci, *Spark in Action*, Manning, 2017
- Holden Karau y Rachel Warren, *High Performance Spark*, O'Reilly, 2017
- Sandy Ryza, Uri Laserson, Sean Owen y Josh Wills, *Advanced Analytics with Spark*, O'Reilly, 2017

Repositorio de la asignatura

- Guiones de sesiones, materiales e información adicional
- Repositorio público: <https://github.com/dsevilla/tcdm-public>
- Rama del curso: **26-27**

```
$ git clone https://github.com/dsevilla/tcdm-public.git  
$ cd tcdm-public  
$ git switch 26-27
```

Los notebooks podrán ejecutarse localmente o en Google Colab y guardarse en Drive o en un repositorio propio.